

コンピュータビジョン

担当: 井尻 敬

05/14 10:30頃に大津法周辺を微修正したものをアップロードしました

Contents

01. 序論 : イントロダクション
02. 特徴検出1 : テンプレートマッチング、コーナー検出、エッジ検出
03. 特徴検出2 : ハフ変換、DoG, SIFT特徴
04. 領域分割 : 領域分割とは、閾値法、領域拡張法、グラフカット法、
05. オプティカルフロー : 領域分割残り, Lucas-Kanade法
06. パターン認識基礎1 : パターン認識概論, サポートベクタマシン
07. パターン認識基礎2 : ニューラルネットワーク、深層学習
08. パターン認識基礎3 : 主成分分析, オートエンコーダ
09. 筆記試験
10. プログラミング演習 1: PC室
11. プログラミング演習 2: PC室
12. プログラミング演習 3: PC室
13. プログラミング演習 4: PC室
14. プログラミング演習 5: PC室

Contents : 画像領域分割

- 画像領域分割とは
- 閾値法
- 領域成長法
- クラスタリング
- グラフカット法
- 動的輪郭モデル(後半)
- 深層学習 (後半)

今回と次回は多様な領域分割法を
広く浅く紹介します

画像領域分割 (Image Segmentation) とは

- 『画像領域分割』『画像領域抽出』『画像ラベリング』とも呼ばれる
- Vision/Graphics/Image Processing 分野において重要な課題
- デジタル画像の各画素にラベルをつける作業
(ラベル画像を作る作業)



Low-level と High-level segmentation

Low-level segmentation

画像を特徴（色等）が一樣な
局所領域に分割する作業



例：Water shed法

High-level segmentation

画像内の目標物の領域を切り
抜く作業

※両者の境界は曖昧で両者の意味を込めて
『画像領域分割』と呼ぶのが一般的



例：Graph Cut法

5

Low-level と High-level segmentation

Low-level segmentation

意味のある固まりを抽出
画像を圧縮
処理の高速化
(画素は直接処理するのに小さすぎる)



例：Water shed法

High-level segmentation

画像編集（エフェクト適用）
コラージュ
シミュレーション用モデルの構築(3D)



例：Graph Cut法


6

Contents：画像領域分割

閾値法 thresholding

閾値法とは

TThresholding.exe




閾値により画素に前景・背景ラベルを付ける
閾値を自動的に計算する方法が研究される
→ Pタイル法[1], 大津法[2], Sauvola法[3]...etc...

- [1] CG-Arts協会. デジタル画像処理
- [2] Otsu N.: A threshold selection method from gray-level histograms. IEEE SMC, 9, 1979, 62-66.
- [3] J. Sauvola et. al., "Adaptive document image binarization," Pattern Recognition 33(2), 225-236, 2000.


8

9

閾値法：大津法



閾値をどこに置けばいい？
二峰を真ん中で分割するのが理想



大津法


二峰性ヒストグラムを仮定し、
二峰を最も良く2分割する閾値を
自動計算する手法

引用数49kを超える論文

10

閾値法：大津法

ヒストグラムの**分離度**を定義しこれを最大化する閾値を探す



画素数

$$\omega = \sum_{i=0}^{255} x_i$$

平均


$$m = \frac{1}{\omega} \sum_{i=0}^{255} x_i \times i$$

分散

$$\sigma^2 = \frac{1}{\omega} \sum_{i=0}^{255} x_i \times (i - m)^2$$

11

ある閾値 t で2領域に分離したとき…



	全体	黒領域	白領域
画素数	ω	ω_1	ω_2
平均	m	m_1	m_2
分散	σ^2	σ_1^2	σ_2^2

黒領域 $\omega_1 = \sum_{i=0}^{t-1} x_i$

$$m_1 = \frac{1}{\omega_1} \sum_{i=0}^{t-1} x_i \times i$$

$$\sigma_1^2 = \frac{1}{\omega_1} \sum_{i=0}^{t-1} x_i \times (i - m_1)^2$$


白領域 $\omega_2 = \sum_{i=t}^{255} x_i$

$$m_2 = \frac{1}{\omega_2} \sum_{i=t}^{255} x_i \times i$$

$$\sigma_2^2 = \frac{1}{\omega_2} \sum_{i=t}^{255} x_i \times (i - m_2)^2$$

12

良い分割、悪い分割をした際に白・黒領域の平均と分散の変化をしてみる



よい分割例

- 白領域・黒領域の分散が小さくなる
- 白領域・黒領域の平均値が離れる

悪い分割例

- 黒領域の分散が大きくなる
- 黒領域・白領域の平均値も近い

ヒストグラムの分割の良さを表す
「分離度」を以下の通り定義

$$\text{分離度} = \frac{\text{クラス間分散} \sigma_b^2}{\text{クラス内分散} \sigma_w^2}$$

クラス内分散

$$\sigma_w^2 = \frac{\omega_1 \sigma_1^2 + \omega_2 \sigma_2^2}{\omega_1 + \omega_2}$$

2領域の分散の平均値
小さい方が良い分割

クラス間分散

$$\sigma_b^2 = \frac{\omega_1 (m_1 - m)^2 + \omega_2 (m_2 - m)^2}{\omega_1 + \omega_2}$$

2領域の平均値の距離の2乗
大きい方が良い分割


13

閾値法：大津法

$$\text{分離度} = \frac{\text{クラス間分散}}{\text{クラス内分散}} = \frac{\sigma_b^2}{\sigma_w^2}$$

$$\sigma_b^2 = \frac{\omega_1(m_1 - m)^2 + \omega_2(m_2 - m)^2}{\omega_1 + \omega_2}$$

$$\sigma_w^2 = \frac{\omega_1\sigma_1^2 + \omega_2\sigma_2^2}{\omega_1 + \omega_2}$$




- 大津法**
- 1) 入力画像のヒストグラムを構築
 - 2) 閾値 t を 1 から 254 まで動かし **分離度** を計算
 - 3) 分離度が最大になる閾値 t_{max} で画像を分割

14



閾値法：大津法

双峰性の高いヒストグラムを持つ画像には強い（そうでない画像には使えない）
グラデーションに弱い → adaptive thresholding




15


閾値法：Adaptive thresholding



各画素 x_{ij} 周囲の局所窓を考える
窓内のヒストグラムから **その画素**
用の閾値 t_{ij} を計算



大津法：局所窓のヒストグラムから大津法を計算



Sauvola法：局所窓の平均値と分散 σ_2 から閾値 t を計算

$$t_{i,j} = m_{i,j} \left(1 + k \left(\frac{\sigma_{i,j}}{R} - 1 \right) \right)$$

$t_{i,j}$ ：画素 i,j の閾値
 $m_{i,j}$ ：窓内の平均
 $\sigma_{i,j}^2$ ：窓内の分散
 R ：最大標準偏差 (= 128)
 k ：パラメータ (= 0.2)

16


まとめ：閾値法

大津法



$$\text{分離度} = \frac{\text{クラス間分散}}{\text{クラス内分散}} = \frac{\sigma_b^2}{\sigma_w^2}$$

Adaptive thresholding



局所窓の情報を利用して閾値計算
大津法 や Sauvola法

閾値により画素に前景ラベル・背景ラベルを付ける
閾値を自動計算する手法（Pタイル法, 大津法, Sauvola法）を紹介した


17

Contents : 画像領域分割

領域成長法 Region Growing

18

領域成長法の概要



- Seed画素から領域を徐々に成長させる (Seedは手で与えるか自動生成する)
- 局所的な規則に従って成長を止める
- Seed配置・成長規則について多くの研究・開発がされている


Adams R. et. al.: Seeded region growing. *IEEE PAMI* 16, 641-647, 1994.
Roerdink J.B.T.M., et. al.: The Watershed Transform: Definitions, Algorithms and Parallelization Strategies, 2000.

19

領域成長法: 二値化

TRegionGrowing.exe

- Seed
- 境界画素 T
- 現在の領域 A



k ステップ後の状態

領域成長法(二値化)

入力: 複数のseed画素

1. Seed画素を前景領域に追加
2. 前景領域に隣接する画素 x のうち次式を満たすもの前景領域に追加
 $|c(seed) - c(x)| < r$ ※
3. 成長が止まるまで(2)を繰り返す

$c(seed)$: seedの画素値
 $c(x)$: 画素 x の画素値
 r : パラメータ


※条件には様々なものが考えられる

20

領域成長法: 多値化

TRegionGrowing.exe

- Seed
- 領域境界画素 T
- 領域 $A1$
- 領域 $A2$



図は k ステップ後の状態

Seeded Region Growing

入力: 領域ID($A1, \dots, A_n$)の付いたSeed


1. 各Seedを領域 $A1, \dots, A_n$ の要素とする
2. 現在成長中の領域に接する画素 x を考え…
 x が複数の領域に接する場合『境界』とする
全 x のうち、次式が最小となる x を A_i に追加
 $\delta(x) = |c(x) - c(A_i)|$ ※ A_i は x が接する領域
3. 全画素を追加するまで(2)を繰り返す

$c(x)$: x の色
 $c(A_i)$: x が隣接する領域 A_i の平均色
※2.において x が複数領域に隣接する場合は境界ラベル (-1など) をつける

[Adams et. al, 1992]

領域成長法の特徴

一様な画素値を持つ領域の分割に適する
ぼけた境界では成長が止まりにくい



22

練習問題

(1) 0-7の値を持つ画像に付いてヒストグラムを計算したところ、右図が得られた。画素値0-4と5-7のグループに分ける場合の、クラス内分散・クラス間分散・分離度を求めよ

値	0	1	2	3	4	5	6	7
個数	3	10	25	8	4	5	20	5

※Google スプレッドシート や excelを使うとよいかもしれません


(2) 0-7の値を持つ10x10画像に対して、赤い画素をシードとした領域拡張を行う。結果として得られる全景画素を示せ。ただし、領域成長には上下左右4近傍を利用し、値が6以上の画素が隣接する場合に領域を成長させるものとする

6	1	3	3	5	7	1	6	7	3
5	5	6	1	4	5	3	3	6	2
5	7	7	7	7	7	7	7	7	3
4	3	7	7	3	6	6	3	2	4
4	6	5	5	5	6	6	4	2	5
2	6	6	3	2	6	6	6	7	5
4	7	6	2	3	7	7	5	6	2
5	7	6	3	1	2	3	5	1	1


23

領域成長法: Watershed Algorithm

[Roerdink J.B.T.M., et. al.: 2000.]



勾配強度を高さと見なすと、勾配強度画像を地形と見なせる
この地形の分水界を境界とする領域分割法




Watershed: 地形学における『分水界』を表す用語:
ある地形のある点に落ちた雨がどこに溜まるかを考える隣接しながらも溜まる先が異なる2点間を領域の境界に
左図はwikipediaより (Public Domain)

25

領域成長法: Watershed Algorithm

[Roerdink J.B.T.M., et. al.: 2000.]




勾配強度を高さと考え水を下から満たしていく
徐々に水位を上げ隣接領域が接した部分を境界とする
領域成長法の言葉で言うと…

- 勾配強度の全ての局所最小点にSeedを配置
- 全領域を同時に成長させ、異なる領域が接した部分を境界にする

26

領域成長法: まとめ



- 局所的な規則に従って領域を成長させる手法
- Seed配置・成長規則に関する研究がなされている
- 単純な二値化 / Seeded Region Growing(多値化)/Watershed法』を紹介

Adams R. et. al.: Seeded region growing. *IEEE PAMI* 16, 641-647, 1994.
 Roerdink J.B.T.M., et. al.: The Watershed Transform: Denitions, Algorithms and Parallelization Strategies, 2000.


27

Contents : 画像領域分割

クラスタリング clustering

28

クラスタリングによる領域分割



画素を**特徴空間**に配置し、特徴空間内で**密集する画素集合（クラスタ）**を発見し分割する

特徴空間 : 色空間, Bilateral空間, テクスチャ空間, etc...

有名な手法 : K-means法[1], Mean shift法[2], Normalized Cut法[3], etc...

[1] 高木幹雄ら, 新編画像解析ハンドブック, 東京大学出版会, 2004.
 [2] Comaniciu D. et. al.: Mean shift: A robust approach toward feature space analysis, *IEEE PAMI*, 24, 5(2002), 603-619.
 [3] Shi J. et. al.: Normalized cuts and image segmentation. *IEEE PAMI*, 22, 8(2002), 888-905.


29

特徴空間とは

特徴空間 : 画像の局所的な特徴が張る空間のこと



RGB空間

$$p_i \rightarrow (R_i \ G_i \ B_i)^T$$



Bilateral空間

$$p_i \rightarrow (p_{i,x} \ p_{i,y} \ I_i)^T$$



Bilateral空間 (Color)


$$p_i \rightarrow (p_{i,x} \ p_{i,y} \ R_i \ G_i \ B_i)^T$$

※ $R_i \cdot G_i \cdot B_i \cdot I_i$ は画素 p_i の R · G · B · 輝度値

他にも...
 テクスチャ特徴/HOG
 /SIFT/HLAC/CHLAC/等



30

k-means clustering (k-平均法)




入力：特徴空間の点群 p_i , クラスタ数 k

1. 各点 p_i にクラスタIDをランダムに割り当てる
2. クラスタ中心 c_j をクラスタの重心に移動
3. 各点 p_i を中心 c_j が最も近いクラスタに割り当てる
4. 変化がなくなるまで2,3を繰り返す



31

k-means clustering (k-平均法)



◆利点

- アルゴリズムが単純で実装が楽
- k を変化させることで、発見できるクラスタ数を変更できる


◆欠点

- 初期割り当てに結果が依存
- 多様なクラスタ形状を扱えない
- クラスタ数 k が既知の必要あり

32

Mean-Shift Clustering (平均シフト法)

点群 $p_i \ i = 1, 2, \dots, N$



Mean Shift Procedure (MSP)

点 y_0 付近の点群密度の局所最大点を発見

入力：点群 p_i , 初期点 y_0 , バンド幅 h

1. $y_{k+1} \leftarrow \frac{\sum_{i=1}^N g_i p_i}{\sum_{i=1}^N g_i}$ $g_i = \begin{cases} 1 & \|p_i - y_k\| \leq h \\ 0 & \|p_i - y_k\| > h \end{cases}$
2. $\|y_{k+1} - y_k\| < \text{閾値}$ まで 1 を繰り返す


Mean Shift Clustering

方法1. 各画素位置 p_i からMSPを行い、近い点に収束した画素を同一クラスタにする

方法2. 特徴空間内に格子状に配置した点群 x_i にMSP行う。同じ点に収束するカーネルが通った画素を同一クラスタにする

33

クラスタリングによる領域分割：まとめ




画素を特徴空間に射影し、その特徴空間内で密度の濃い部分を同一領域として分割する

- 特徴空間の選択とクラスタの発見法が大切
- k -平均法 Mean Shift法 を紹介した
- 画像領域分割の文脈ではあまり使われないが、クラスタ探索はとても大切

34

練習問題

(1) クラスAに属するサンプル点10個と、クラスBに属するサンプル点10個が2次元の特徴空間に分布している。このデータに対して、 $k=2$ としてk-meansクラスタリングを行った際、うまくクラスタを発見できない分布の例を2つ挙げ、それぞれについてうまくいかない理由を述べよ。



(2) k-meansクラスタリングを適用可能な、画像処理以外の課題を一つ挙げ、k-meansクラスタリングがどのように活用できるか簡潔に説明せよ。

35

Contents : 画像領域分割

グラフカット法 Graph Cut

37

グラフカット領域分割

前傾制約 背景制約




前景・背景に属する画素を適当に入力すると、これを制約に画像を二値化
二値化をエネルギー最小化問題として定式化し、フローネットワークの最小
カットにより最適解を計算する

臓器などの塊状領域に対してはかなり強力な領域分割法


38

準備：フローネットワーク



フローネットワーク

- 容量付き有向グラフ $G = (V, E)$
- 頂点集合 V と辺集合 E から成る
- 辺 (p, q) は容量 $c_{pq} > 0$ を持つ
- 始点 s と終点 t を含む



フロー

- 各辺には容量を超えない範囲でフローが流れる
- ある頂点 v について、流入するフローと流出するフローは等しい
- 総流量：始点から出るフローの総和
- 最大フロー：ネットワークに流せる最大の総流量

39

準備：フローネットワーク

カット:

頂点を『 s を含む部分集合 S 』と『 t を含む部分集合 T 』に分割する

カットセット:


部分集合 S と T の間をつなぐ辺の集合

カットの容量:


カットセットのうち $S \rightarrow T$ 方向の辺の容量総和（逆向きの辺は無視する）

最小カット

容量が最小となるカット



カット : $S = \{s, v2\}$, $T = \{v1, v3, v4, v5, t\}$
 カットセット : $\{(s, v1), (v1, v2), (v2, v3), (v2, v5)\}$
 カット容量 : $5 + 2 + 2 = 9$



最小カット : $S = \{s, v1, v2\}$, $T = \{v3, v4, v5, t\}$
 カット容量 : $1 + 2 + 2 = 5$

40

準備：フローネットワーク


最大フロー最小カットの定理

任意のフローネットワークにおいて、その**最大フロー**と**最小カット**は等しい

最大フローはネットワークの一番細い部分(最小カット)によって決定される

※ 最大フローが流れているとき、始点 s から不飽和辺のみを使って到達できる頂点群を S とし、 $T = V - S$ とすると、 $S - T$ は最小カットをなす

※ 最大フロー・最小カットの探索には様々なアルゴリズムが存在し、比較的高速に“解ける”ことを知っておいてください




41

最大フローアルゴリズム


補足資料

残余ネットワーク G^f とは、フローネットワーク G にフローが流れているとき、フローの可変範囲を表すネットワークのこと

増加可能経路とは、残余ネットワーク内の $s \rightarrow t$ 経路のこと



フローネットワーク G




残余ネットワーク G^f

42

最大フローアルゴリズム

補足資料




最大フローアルゴリズム（単純なもの）

入力：フローネットワーク G

出力：最大フローと最小カット

1. フローを0で初期化
2. 残余ネットワークを構築
3. 増加可能経路 P が無くなるまで下を繰り返す
 - 3-1) 増加可能経路 P の探索
 - 3-2) 経路 P に沿ってフロー追加




増加可能経路 P がなくなったら、 S と接続する全頂点をグループ S に。

43

グラフカットを用いた最適化

入力：画像 / 前景画素 / 背景画素



1) 画像からフローネットワークを構築

- 頂点: 全画素、始点 s 、終点 t
- 辺
- 始点 s から全画素へ（前景制約と似た色には太い辺を配置）
- 全画素から終点 t へ（背景制約と似た色には太い辺を配置）
- 隣接画素間にも配置

2) ネットワークの最小カットを計算

※なるべく細い辺だけを切ってネットワークを2分割する

- s に連結する画素にラベル *fore* をつける
- t に連結する画素にラベル *back* をつける

44

グラフカット領域分割：コスト関数



入力：画像、制約画素集合（前景 F ・背景 B ）

出力：以下を満たす二値化

- 制約画素 p は必ず制約を満たす
- 非制約画素 p は、その特徴(色など)が前景画素 F に近ければ前景に、 B に近ければ背景になる
- 境界は特徴の異なる画素間を通る

$$\operatorname{argmin}_{\{L_p \mid p \in \Omega\}} \sum_{p \in \Omega} E_1(L_p) + \lambda \times \sum_{(p,q) \in \mathcal{N}} E_2(L_p, L_q)$$

Ω : 全画素集合
 $\mathcal{N}$: 近傍画素集合
 L_p : 画素 $p \in \Omega$ につくラベル値 $\{fore, back\}$ のどちらか



45

グラフカット領域分割：コスト関数

$$\operatorname{argmin}_{\{L_p \mid p \in \Omega\}} \sum_{p \in \Omega} E_1(L_p) + \lambda \times \sum_{(p,q) \in \mathcal{N}} E_2(L_p, L_q)$$


Ω : 全画素集合
 $\mathcal{N}$: 近傍画素集合
 L_p : ラベル値 $\{fore, back\}$

$E_1(L_p)$: 『データ項』 画素 p のラベル付の不正確さに反応する項

画素 p が前景制約画素に似ているなら...

$$E_1(L_p = fore) \leftarrow \text{小}$$

$$E_1(L_p = back) \leftarrow \text{大}$$



定義は論文によって色々
右は一例

$$E_1(L_p = fore) = \begin{cases} 0 & p \in F \\ \infty & p \in B \\ t_p^{fore} & \text{other} \end{cases}$$

$$E_1(L_p = back) = \begin{cases} \infty & p \in F \\ 0 & p \in B \\ t_p^{back} & \text{other} \end{cases}$$

$$t_p^{fore} = \frac{d_p^F}{d_p^F + d_p^B}, t_p^{back} = \frac{d_p^B}{d_p^F + d_p^B}$$

※ c_p は画素 p の画素値
 $d_p^F = \min_{k \in F} \|c_p - c_k\|$ ※ t_p^{fore} は画素 p の色が前景画素に似るほど小さくなるよう指定する
 $d_p^B = \min_{k \in B} \|c_p - c_k\|$

46

グラフカット領域分割：コスト関数

$$\operatorname{argmin}_{\{L_p \mid p \in \Omega\}} \sum_{p \in \Omega} E_1(L_p) + \lambda \times \sum_{(p,q) \in \mathcal{N}} E_2(L_p, L_q)$$

Ω : 全画素集合
 $\mathcal{N}$: 近傍画素集合
 L_p : ラベル値 $\{fore, back\}$

$E_2(L_p, L_q)$: 『平滑化項』 隣り合う画素が似た特徴（色）を持つときは、なるべく同じラベルをつける


☆隣接画素 p, q に同じラベルをつける

$$\rightarrow E_2 = 0$$

☆隣接画素 p, q に違うラベルをつける

p, q が似た色を持つ $\rightarrow E_2$ は大

p, q が遠い色を持つ $\rightarrow E_2$ は小



定義は論文によって色々
右は一例

$$E_2(L_p, L_q) = \begin{cases} 0 & L_p = L_q \\ \frac{1}{1 + \|c_p - c_q\|} & \text{other} \end{cases}$$

※ c_p は画素 p の画素値

47


グラフカット領域分割：コスト関数

$$\operatorname{argmin}_{\{L_p \mid p \in \Omega\}} \sum_{p \in \Omega} E_1(L_p) + \lambda \times \sum_{(p,q) \in \mathcal{N}} E_2(L_p, L_q)$$

Ω : 全画素集合
 $\mathcal{N}$: 近傍画素集合
 L_p : ラベル値 $\{fore, back\}$

この問題は解くのが難しい

- 局所最小解が多い
- 全通り検索する↓？ さすがに組み合わせが多すぎ (3×4 画像でも $2^{12} = 4096$ 通り)



『この問題の大域最小化解は、フローネットワークの最小カットにより高速に求められる』 [Boykov Y., Jolly M-P. *MICCAI*, 276-286, 2000.]

※ L_p が二状態をとる場合 (二値化) に限る

※グラフカット発見以前はやきなまし法 (ランダムウォーク) で解いていた

48

グラフカットを用いた最適化

$$\operatorname{argmin}_{\{L_p \mid p \in \Omega\}} \sum_{p \in \Omega} E_1(L_p) + \lambda \times \sum_{(p,q) \in \mathcal{N}} E_2(L_p, L_q)$$

画像からフローネットワークを構築

- 頂点 V : 全画素, 始点 s , 終点 t
- 辺 E : 右図


フローネットワークをカットし

- s に連結する画素にラベル *fore* をつける
- t に連結する画素にラベル *back* をつける

→ カット容量 がコストに対応する

→ 最小カットを求めればコスト最小化できる

49



$$E_1(L_p = back) + E_1(L_q = fore) + E_1(L_r = fore) + E_2(L_p, L_q)$$



グラフカット領域分割

利点

高速・高精度
高次元化が容易
UIと相性がよい

欠点

境界が不明瞭な領域には利用し難い
血管・筋膜等、細い・薄い形状には不向き



50

まとめ：画像領域分割

- 画像領域分割とは
- 閾値法
- 領域成長法
- クラスタリング
- グラフカット法
- 動的輪郭モデル(後半)
- 深層学習 (後半)

51