

# コンピュータビジョン

担当: 井尻 敬

## Contents


- 01. 序論 : イントロダクション
- 02. 特徴検出1 : テンプレートマッチング、コーナー検出、エッジ検出
- 03. 特徴検出2 : ハフ変換、DoG, SIFT特徴
- 04. 領域分割 : 領域分割とは、閾値法、領域拡張法、グラフカット法、
- 05. オプティカルフロー : 領域分割残り, Lucas-Kanade法
- 06. パターン認識基礎1 : パターン認識概論, サポートベクタマシン
- 07. パターン認識基礎2 : ニューラルネットワーク、深層学習
- 08. パターン認識基礎3 : 主成分分析, オートエンコーダ
- 09. 筆記試験
- 10. プログラミング演習 1: PC室
- 11. プログラミング演習 2: PC室
- 12. プログラミング演習 3: PC室
- 13. プログラミング演習 4: PC室
- 14. プログラミング演習 5: PC室

## パターン認識とは1

## パターン認識

『データの中の規則性を自動的に見つけ出し、その規則性を使ってデータを異なるカテゴリに分類する処理』 (PRML, C.M. Bishop)

例) 手書き文字画像の認識




## パターン認識

パターン認識は多様な分野で多様なデータに対して応用されている

データ	研究分野
画像	画像認識 (Computer vision)
手書き文字	文字認識 (Optical character recognition)
音声	音声認識 (Speech recognition)
Genome	Bioinformatics
生体	Biometrics
:	:

5

## 身近な応用例 – 文字認識



Windows IME pad

読めない漢字の手書きにより検索を支援

6

## 身近な応用例 - 音声認識



7


## 身近な応用例 – その他



指紋認証



顔認識



© IEEE Trans. Cyber. Hubert Shum, et al.

姿勢追跡  
ジェスチャ認識

8

## パターン認識

『データの中の規則性を自動的に見つけ出し、その規則性を使ってデータを異なるカテゴリに分類する処理』 (PRML, C.M. Bishop)

### 1) クラス分類 Classification

『複数の入力データを **既知** のクラスに分類する』

※クラス分類のみをパターン認識と呼ぶ事もある

### 2) クラスタリング Clustering


『複数の入力データから **未知** の類似したグループ (クラスター) を発見する』

9

### 1) クラス分類 Classification

『複数の入力データを **既知** のクラスに分類する』

例) 果物の写真を、 **リンゴ・バナナ・みかんの3クラス** に分類せよ




10

### 2) クラスタリング Clustering

『複数の入力データから **未知** の類似したグループ (クラスター) を発見する』

例) 果物の写真を、 **類似したグループ** を発見せよ



11

## パターン認識

『データの中の規則性を自動的に見つけ出し、その規則性を使ってデータを異なるカテゴリに分類する処理』 (PRML, C.M. Bishop)

### 1) クラス分類 Classification **本日の対象はこちら**

『複数の入力データを **既知** のクラスに分類する』

※クラス分類のみをパターン認識と呼ぶ事もある

### 2) クラスタリング Clustering

『複数の入力データから未知の類似したグループ (クラスター) を発見する』

12

## パターン認識とは2

13

『写真を、リンゴ・バナナ・みかんの3クラスに分類せよ』

入力1: 正解画像群

- クラスIDが既に付いた画像群
- 教師データと呼ばれる



ID: リンゴ




ID: バナナ



ID: ミカン

入力2: 分類対象画像群


この画像にクラスIDを付与するのが目的



14

『写真を、リンゴ・バナナ・みかんの3クラスに分類せよ』

**前処理:** 画像から前景領域を抽出する



自動分割に関する既存手法は多いのでどれかを使う

- Otsu method,
- Grab cut,
- Saliency map + graph cut
- などなど



15

『写真を、リンゴ・バナナ・みかんの3クラスに分類せよ』

**特徴抽出:** 画像からクラスを良く分離する特徴量（数値データ）を抽出する

特徴の例1) 平均色相

- 前景領域の平均の色
- HSV色空間の色相H



16

## 『写真を、リンゴ・バナナ・みかんの3クラスに分類せよ』

**特徴抽出:** 画像からクラスを良く分離する特徴量（数値データ）を抽出する

特徴の例2) 円形度：領域が円に近い度合

$$\frac{A}{L^2/4\pi}$$

A: 領域の面積

L: 領域の周囲長

$L^2/4\pi$ : 周囲長Lの円の面積



円形度 1.0



円形度 0.785



円形度 0.604



円形度  
0.836



0.519




0.793

## 『写真を、リンゴ・バナナ・みかんの3クラスに分類せよ』

**特徴抽出:** 画像からクラスを良く分離する特徴量（数値データ）を抽出する

(1)平均色相と(2)円形度により、入力画像を**2D空間**に配置できる

特徴空間



## 『写真を、リンゴ・バナナ・みかんの3クラスに分類せよ』

**識別:** 特徴空間に入力画像を配置し、クラスIDを割り当てる

1. 正解画像を特徴空間に配置



ID: リンゴ


ID: バナナ

ID: みかん


2. 分類したい画像も特徴空間に配置し  
距離が一番近い正解画像のIDを付与




※ Nearest neighbor 法



## クラス分類の一般的な処理手順



## クラス分類の一般的な処理手順




特徴抽出のための前処理

データが画像ならば…

二値化、平滑化、先鋭化、特徴保存平滑化、など

## クラス分類の一般的な処理手順



入力データ群に対し、同じクラスは近く・異なるクラス遠くなるような特徴空間にデータを射影する


良い特徴空間を構築するには、知識・経験・試行錯誤が必要

画像認識：HLAC・SIFT・HoG特徴などが有名

※最近流行りの深層学習は特徴量の設計もデータから学習する

※深層学習の発展に伴い、人がデザインした特徴量は「Hand Craftな」特徴量と呼ばれる

## クラス分類の一般的な処理手順



正解データ群を利用して特徴空間を分割する（訓練）

識別対象を特徴空間に射影し、上記の分割結果を用いてラベル（ID）を割り振る

### クラス分類の手法

K-Nearest Neighbor, ベイズ決定則, 決定木 (random forests), サポートベクタマシン  
ニューラルネットワーク, etc…

## まとめ：パターン認識とは

『データの中の規則性を自動的に見つけ出し、その規則性を使ってデータを異なるカテゴリに分類する処理』 (PRML, C.M. Bishop)


### 1) クラス分類 Classification

複数の入力データを **既知** のクラスに分類する  
※クラス分類のみをパターン認識と呼ぶ事もある

### 2) クラスタリング Clustering

複数の入力データから未知の類似したグループ（クラスター）を発見する

クラス分類の一般的な手順は以下の通り



## 練習

色相と円形度だけを使って果物画像を識別したところ、「ばなな」と「みかん」がしばしば混同される結果となりました。

(1)この誤識別の原因として最も適切なものを1つ選びなさい。

- A. 識別すべきクラスが3クラスと多すぎるため
- B. 色相と円形度という特徴では、ばななとみかんを十分に区別できない
- C. バナナは画像中で傾いて撮影されるため円形度が安定して取得できない
- D. 色相と円形度の値が似た画像が、教師データに多く含まれていたため

(2)この誤識別への対処法として適切なものを一つ選びなさい

- A. 前景領域のエッジ強度など、追加の特徴量を導入する
- B. 果物の種類を減らして2クラスの識別問題に単純化する
- C. 色相と円形度の軸の重みを変化させた特徴空間を利用する
- D. 果物画像のコントラストを上げる前処理をする

識別用の特徴空間の設計方針に付いて正しいものをすべて選択しなさい

- A. 同じクラスの教師データが近くに集まるようにする
- B. 同じクラスの教師データが近くに集まらないようにする
- C. 違うクラスの教師データが近くに集まるようにする
- D. 違うクラスの教師データが近くに集まらないようにする
- E. 特徴量は多ければ多いほど、常に識別性能が向上する
- F. 異なる特徴量を組み合わせること、識別精度が向上する可能性が高くなる
- G. 識別時に距離計算をするため特徴空間は必ず2次元にする必要がある



25

## 識別器1

27

## 識別器


- 教師データ（ラベルつき特徴ベクトル）から特徴空間の分割方法を学習し、未知データにラベル付けを行なう手法
- プロトタイプ法, kNN (k-Nearest-Neighbor法), SVM (Support Vector Machine) RM (Random Forest)



28

## プロトタイプ法

- 各クラスを代表する点を選択（作成）
  - ↑これをプロトタイプと呼ぶ
  - 代表的なデータをプロトタイプにする
  - クラス内データの平均値をプロトタイプにする
- 未知データを特徴空間に配置し、最も近いプロトタイプのラベルを識別結果とする




29

## プロトタイプ法 と マハラノビス距離

プロトタイプまでの距離で識別するのはOK  
でも明らかに分布の形が異なるクラス同士を  
ユークリッド距離で比較していいの？

右図において…

- 赤:平均(2,2), 分散共分散 $\begin{pmatrix} 3 & 0 \\ 0 & 3 \end{pmatrix}$ のガウス分布
- 青:平均(10,2), 分散共分散 $\begin{pmatrix} 0.3 & 0 \\ 0 & 0.3 \end{pmatrix}$ のガウス分布
- 未知データ (6,2)はどちらのクラス？



30

## マハラノビス距離とは

- データ点群のばらつきを考慮した距離のこと
- 『N個の点群  $\mathbf{x}_i \in R^d$ 』と『点  $\mathbf{p} \in R^d$ 』の距離を計算する

N個の点群  $\mathbf{x}_i \in R^d$  の平均と分散共分散行列は…

$$\text{平均: } \mathbf{m} = \frac{1}{N} \sum_i \mathbf{x}_i$$

$$\text{分散共分散: } \mathbf{S} = \frac{1}{N} \sum_i (\mathbf{x}_i - \mathbf{m})(\mathbf{x}_i - \mathbf{m})^T$$

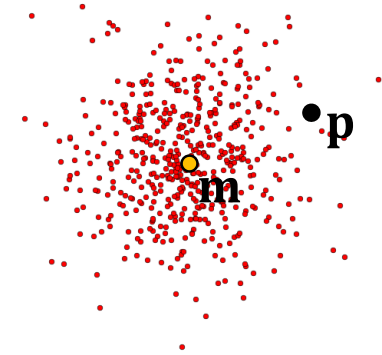
点群の重心 $\mathbf{m}$ と点 $\mathbf{p}$ のユークリッド距離:

$$d = \sqrt{(\mathbf{p} - \mathbf{m})^T (\mathbf{p} - \mathbf{m})}$$

点群の重心 $\mathbf{m}$ と点 $\mathbf{p}$ のマハラノビス距離:

$$d = \sqrt{(\mathbf{p} - \mathbf{m})^T \mathbf{S}^{-1} (\mathbf{p} - \mathbf{m})}$$


※マハラノビス距離は点群の分布を考慮し、分散の  
大きさの逆数で正規化した距離と考えられる



31

## プロトタイプ法 と マハラノビス距離

- 赤:平均(2,2), 分散共分散 $\begin{pmatrix} 3 & 0 \\ 0 & 3 \end{pmatrix}$ のガウス分布
- 青:平均(10,2), 分散共分散 $\begin{pmatrix} 0.3 & 0 \\ 0 & 0.3 \end{pmatrix}$ のガウス分布
- マハラノビス距離を用いた場合未知データ (6,2)はど  
ちらのクラス？



赤点との距離:

$$\begin{aligned} & \left\{ \left( \begin{pmatrix} 6 \\ 2 \end{pmatrix} - \begin{pmatrix} 2 \\ 2 \end{pmatrix} \right)^T \begin{pmatrix} 3 & 0 \\ 0 & 3 \end{pmatrix}^{-1} \left( \begin{pmatrix} 6 \\ 2 \end{pmatrix} - \begin{pmatrix} 2 \\ 2 \end{pmatrix} \right) \right\}^{\frac{1}{2}} \\ &= \left\{ \begin{pmatrix} 4 \\ 0 \end{pmatrix} \begin{pmatrix} 1/3 & 0 \\ 0 & 1/3 \end{pmatrix} \begin{pmatrix} 4 \\ 0 \end{pmatrix} \right\}^{\frac{1}{2}} \\ &= \left\{ \frac{16}{3} \right\}^{\frac{1}{2}} = \sqrt{\frac{16}{3}} \end{aligned}$$


青点との距離:

$$\begin{aligned} & \left\{ \left( \begin{pmatrix} 6 \\ 2 \end{pmatrix} - \begin{pmatrix} 10 \\ 2 \end{pmatrix} \right)^T \begin{pmatrix} 0.3 & 0 \\ 0 & 0.3 \end{pmatrix}^{-1} \left( \begin{pmatrix} 6 \\ 2 \end{pmatrix} - \begin{pmatrix} 10 \\ 2 \end{pmatrix} \right) \right\}^{\frac{1}{2}} \\ &= \left\{ \begin{pmatrix} -4 \\ 0 \end{pmatrix} \begin{pmatrix} 10/3 & 0 \\ 0 & 10/3 \end{pmatrix} \begin{pmatrix} -4 \\ 0 \end{pmatrix} \right\}^{\frac{1}{2}} \\ &= \left\{ \frac{160}{3} \right\}^{\frac{1}{2}} = \sqrt{\frac{160}{3}} \end{aligned}$$

32

## kNN(k-Nearest Neighbor法)

- 特徴空間において、未知データに対し、距  
離が最も近いk個の教師データを検索し、  
その点の多数決でラベルを決定する
- 特徴空間の次元が低く教師データの量が十  
分多いときには高い精度が得られる
- 全教師データを保持するのでメモリ消費が  
大きい
- 素朴な実装をすると計算量も大きくなる



33




## 練習


2次元空間に分布する点群の平均が $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$ , 分散共分散行列が $\begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}$ である。

この点群と点 $\begin{pmatrix} 4 \\ 9 \end{pmatrix}$ のマハラノビス距離を計算せよ

2次元の特徴空間に赤・青のデータ点が分布しておりkNN法を適用する。k=1のとき赤と判定される部分空間（領域）を図示せよ



2次元の特徴空間に赤・青のデータ点が分布しておりkNN法を適用する。k=3のとき赤と判定される部分空間（領域）を図示せよ



34

## 識別器2

36

## 決定木 (classification tree / decision tree)


二分木でクラス分類を表現

**Node** : 分割規則が定義される

**Leaf** : クラスに対応

・未知点Xについて → 木を辿り分類先を決定

- ・分類 (test) が高速
- ・実装が簡単
- ・木が深くなると過学習



37

## 決定木 (classification tree / decision tree)


二分木でクラス分類を表現

**Node** : 分割規則が定義される

**Leaf** : クラスに対応

・未知点Xについて → 木を辿り分類先を決定

- ・分類 (test) が高速
- ・実装が簡単
- ・木が深くなると過学習




38

## 決定木の学習 (概要) [Fielding 77; Quinlan 93; Breiman 84]

入力: 教師データ  $(Y_i, \mathbf{X}_i)$ , 木の深さ  $D$

1. Root に全教師データを関連付け
2. 深さが  $D$  になるまで以下を繰り返す
  - + Node  $d$  に注目
  - +  $d$  に属すデータ群を二分割するルールを決定
    - ランダムに候補を作成
    - **なるべく偏りが大きなルールを選択**
  - +  $d$  の子に分割したデータ群を関連付け
3. 葉にラベル付け (属するデータの多数決)

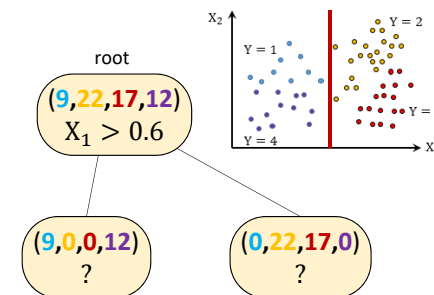


39

## 決定木の学習 (概要) [Fielding 77; Quinlan 93; Breiman 84]

入力: 教師データ  $(Y_i, \mathbf{X}_i)$ , 木の深さ  $D$

1. Root に全教師データを関連付け
2. 深さが  $D$  になるまで以下を繰り返す
  - + Node  $d$  に注目
  - +  $d$  に属すデータ群を二分割するルールを決定
    - ランダムに候補を作成
    - **なるべく偏りが大きなルールを選択**
  - +  $d$  の子に分割したデータ群を関連付け
3. 葉にラベル付け (属するデータの多数決)

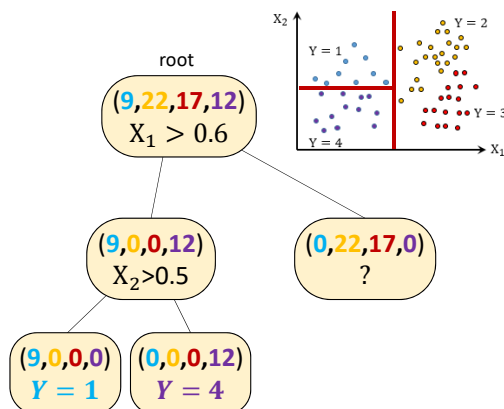


40

## 決定木の学習 (概要) [Fielding 77; Quinlan 93; Breiman 84]

入力: 教師データ  $(Y_i, \mathbf{X}_i)$ , 木の深さ  $D$

1. Root に全教師データを関連付け
2. 深さが  $D$  になるまで以下を繰り返す
  - + Node  $d$  に注目
  - +  $d$  に属すデータ群を二分割するルールを決定
    - ランダムに候補を作成
    - **なるべく偏りが大きなルールを選択**
  - +  $d$  の子に分割したデータ群を関連付け
3. 葉にラベル付け (属するデータの多数決)




41

## 決定木の学習 (概要) [Fielding 77; Quinlan 93; Breiman 84]

入力: 教師データ  $(Y_i, \mathbf{X}_i)$ , 木の深さ  $D$

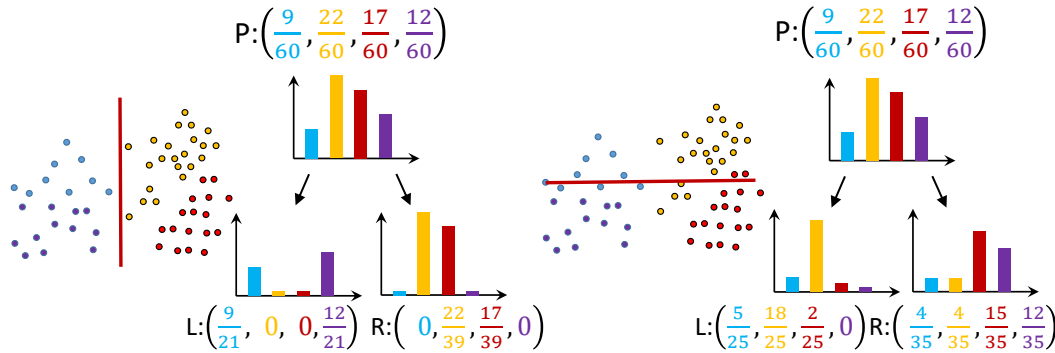
1. Root に全教師データを関連付け
2. 深さが  $D$  になるまで以下を繰り返す
  - + Node  $d$  に注目
  - +  $d$  に属すデータ群を二分割するルールを決定
    - ランダムに候補を作成
    - **なるべく偏りが大きなルールを選択**
  - +  $d$  の子に分割したデータ群を関連付け
3. 葉にラベル付け (属するデータの多数決)



42

## なるべく偏りが大きなルールを選択

つぎの二通りの分割ならどちらが良い分割でしょうか？



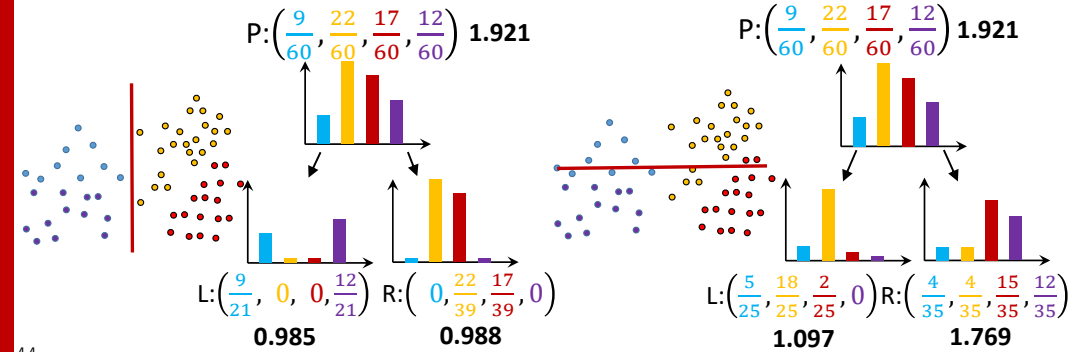
43

## なるべく偏りが大きなルールを選択

データ点の割合を出現確率と考えて、エントロピーを計算してみると・・・

$$\text{Entropy: } H = -\sum_{c=1}^k P_c \log P_c$$

※全クラスの出現確率が均等なほどエントロピーは大  
※全クラスの出現確率が偏るとエントロピーは小



44

## なるべく偏りが大きなルールを選択

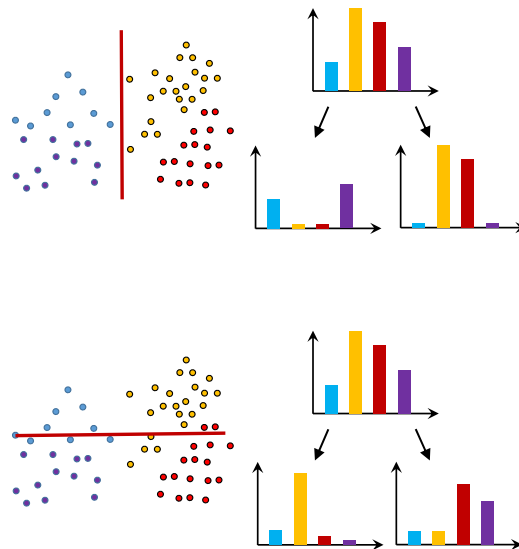
→ 情報利得が大きくなる分割を選択

$$\text{情報利得: } H_p - \frac{|N_L|}{|N_p|} H_L - \frac{|N_R|}{|N_p|} H_R$$

分割により減少したエントロピーを表す

$H_p/H_L/H_R$ : 親/左/右Nodeのエントロピー

$N_p/N_L/N_R$ : 親/左/右Nodeに属す要素数



45

## 参考資料 (計算式)

各点の出現確率

$$P: \left(\frac{9}{60}, \frac{22}{60}, \frac{17}{60}, \frac{12}{60}\right) \quad L: \left(\frac{9}{21}, 0, 0, \frac{12}{21}\right) \quad R: \left(0, \frac{22}{39}, \frac{17}{39}, 0\right)$$

$$H_p = -\frac{9}{60} \log \frac{9}{60} - \frac{22}{60} \log \frac{22}{60} - \frac{17}{60} \log \frac{17}{60} - \frac{12}{60} \log \frac{12}{60} = 1.921$$

$$H_L = -\frac{9}{21} \log \frac{9}{21} - 0 - 0 - \frac{12}{21} \log \frac{12}{21} = 0.985$$


$$H_R = -0 - \frac{22}{39} \log \frac{22}{39} - \frac{17}{39} \log \frac{17}{39} - 0 = 0.988$$

$$\text{情報利得: } 1.921 - \frac{21}{60} 0.985 - \frac{39}{60} 0.988 = 0.934$$

※ 底は2を利用

46

## 参考資料 (計算式)




$$H_P = -\frac{9}{60} \log \frac{9}{60} - \frac{22}{60} \log \frac{22}{60} - \frac{17}{60} \log \frac{17}{60} - \frac{12}{60} \log \frac{12}{60} = 1.921$$

$$H_L = -\frac{5}{25} \log \frac{5}{25} - \frac{18}{25} \log \frac{18}{25} - \frac{2}{25} \log \frac{2}{25} = 1.097$$

$$H_R = -\frac{4}{35} \log \frac{4}{35} - \frac{4}{35} \log \frac{4}{35} - \frac{15}{35} \log \frac{15}{35} - \frac{12}{35} \log \frac{12}{35} = 1.769$$

$$\text{情報利得} : 1.921 - \frac{25}{60} 1.097 - \frac{35}{60} 1.769 = \mathbf{0.432}$$

47



情報利得 : 0.934

情報利得 : 0.432

左の分割のほうが情報利得が高い (偏りが大きい)  
→ この二つの候補があったら左を選ぶ

48

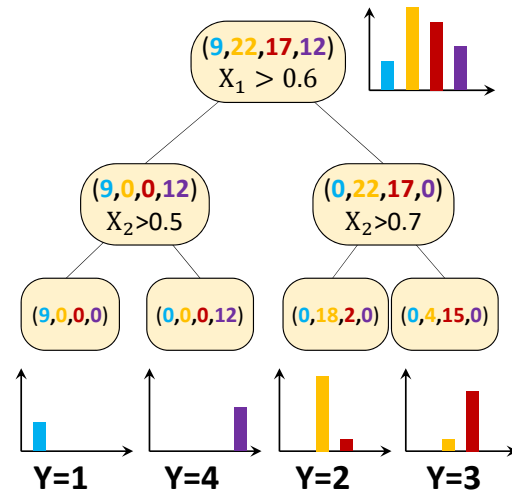
## 参考資料

### 葉にラベル付け

Nodeの分割を繰り返して指定された深さの木を作ったら…

→ 葉にラベルをつける

葉に属すデータ点のうち出現確率が最大のもののラベルを選択 (単純ベイズ、多数決)



49

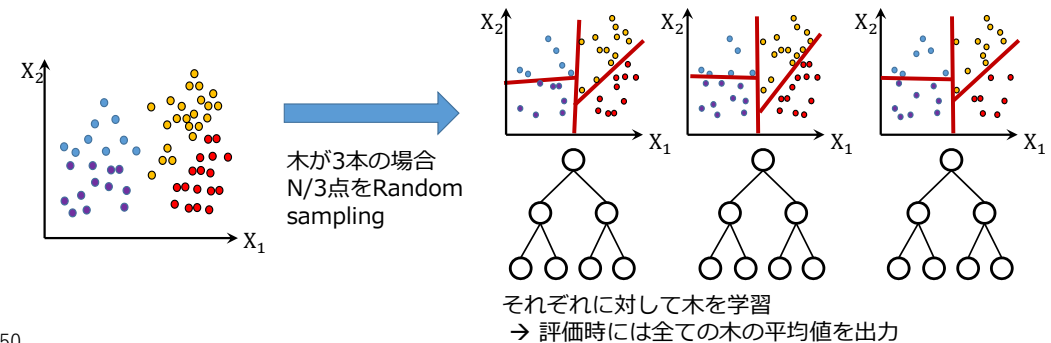
## 集団学習 (Ensemble learning)

弱識別器を多数組み合わせることで強識別器を実現する

弱識別器 : 精度の低い識別器

強識別器 : 精度の高い識別器

決定木 → ランダム森(Random Forests)




50

# Support Vector Machine

- 特徴空間が超平面（2次元なら直線）で分離可能なとき・・・
- 超平面と最も近いデータ点との距離が最大となるような超平面を選択する
  - これをマージン最大化という
  - 最近傍点をサポートベクトルという
- 超平面の方程式だけを記録すればよいのでメモリ消費が少ない


※線形分離不可能な場合  
→ ソフトマージンSVM  
→ カーネルトリック



51


## まとめ: 識別器

- 識別器: 教師データに基づき特徴空間を分割することで, 未知データへのラベル付けを行なう
- 特に有名な下の識別器を紹介
  - プロトタイプ法
  - K Nearest Neighbor
  - Random Forests
  - Support Vector Machine



52

## 余談: kd-tree (時間があれば。。)




- K-dimensional tree
- 2分木構造により空間を分割し, 高速な近傍探索を可能にする
- 近傍探索の計算複雑度は
  - 平均  $O(\log N)$
  - 最悪ケース  $O(N)$

53

54

## kd-treeの構築



### • 下を繰り返す


空間を分割する軸を決定し軸に沿って点群をソート

中央の点を現在ノードに割り当て、左側の点群を左の子に、右側の点群を右の子にする



55


## kd-treeの構築



### • 下を繰り返す


空間を分割する軸を決定し軸に沿って点群をソート

中央の点を現在ノードに割り当て、左側の点群を左の子に、右側の点群を右の子にする



56


## kd-treeの構築



### • 下を繰り返す


空間を分割する軸を決定し軸に沿って点群をソート

中央の点を現在ノードに割り当て、左側の点群を左の子に、右側の点群を右の子にする



57


## kd-treeの構築



### • 下を繰り返す


空間を分割する軸を決定し軸に沿って点群をソート

中央の点を現在ノードに割り当て、左側の点群を左の子に、右側の点群を右の子にする



58


## kd-treeの構築




### 点pの最近傍点探索

木を下方方向にたどり葉ノードを見つけ、これを暫定的な最近傍点とする（近似解でよければここで終了）

到達した葉ノードから木を上方向にたどり、点pからの距離がR以下の領域は検索する、




## kd-treeの構築




### 点pの最近傍点探索

木を下方方向にたどり葉ノードを見つけ、これを暫定的な最近傍点とする（近似解でよければここで終了）

到達した葉ノードから木を上方向にたどり、点pからの距離がR以下の領域は検索する、



## kd-treeの構築



### 点pの最近傍点探索

木を下方方向にたどり葉ノードを見つけ、これを暫定的な最近傍点とする（近似解でよければここで終了）

到達した葉ノードから木を上方向にたどり、点pからの距離がR以下の領域は検索する、

